

Raport Project „Student Performance”

Acest proiect are ca scop analiza setului de date Student Performance, folosind tehnici de procesare a datelor, clasificare, clustering si vizualizare. Prin aceste etape, se urmareste intelegerea factorilor care influenteaza performanta scolara si evaluarea comportamentului elevilor din perspective diferite.

1. Preprocesarea Datelor

Pentru aceasta tema am ales setul de date Student_Performance, bazat pe performanta elevilor, asupra caruia am aplicat mai multe operatii pentru a-l aduce intr-o forma potrivita pentru analiza.

Dupa descarcarea locala, am importat fisierul student-mat.csv, care contine informatii despre elevi, precum scoala, varsta, absentele si notele. Dupa incarcarea datelor, am verificat structura tabelului si tipurile de valori pentru a ma asigura ca informatiile sunt citite corect.

	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z	AA	AB	AC	AD	AE	AF	AG	AH
1	Status	Medu	Fedu	Mjob	Fjob	reason	guardian	traveltime	studytime	failures	schoolsup	famsup	paid	activities	nursery	higher	internet	romantic	famrel	freetime	goout	Dalc	Walc	health	absences	G1	G2	G3	
2	A	4	4	at_home	teacher	course	mother	2	2	0	yes	no	no	yes	yes	no	no	no	no	4	3	4	1	1	3	4	0	11	11
3	T	1	1	at_home	other	course	father	1	2	0	no	yes	no	no	yes	yes	no	yes	no	5	3	3	1	1	3	2	9	11	11
4	T	1	1	at_home	other	other	mother	1	2	0	yes	no	no	yes	yes	yes	no	yes	no	4	3	2	2	3	3	6	12	13	12
5	T	4	2	health	services	home	mother	1	3	0	no	yes	no	yes	yes	yes	yes	yes	no	3	2	2	1	1	5	0	14	14	14
6	T	3	3	other	other	other	mother	1	2	0	no	yes	no	yes	yes	yes	yes	yes	no	4	3	2	1	2	5	0	11	13	13
7	T	4	3	services	other	reputation	mother	1	2	0	no	yes	no	yes	yes	yes	yes	no	no	5	4	2	1	2	5	6	12	12	13
8	T	2	2	other	other	home	mother	1	2	0	no	no	no	no	yes	yes	yes	no	no	4	4	4	1	1	3	0	13	12	13
9	A	4	4	other	teacher	home	mother	2	2	0	yes	no	no	yes	yes	yes	no	no	no	4	1	4	1	1	1	2	10	13	13
10	A	3	2	services	other	home	mother	1	2	0	no	yes	no	no	yes	yes	yes	no	no	4	2	2	1	1	1	0	15	16	17
11	T	3	4	other	other	home	mother	1	2	0	no	yes	no	yes	yes	yes	yes	no	no	5	5	1	1	1	5	0	12	12	13

Am verificat daca exista valori lipsa, insa setul de date este complet. In cazul in care ar fi existat, valorile numerice ar fi putut fi completate cu media, iar valorile text cu moda, insa aceasta decizie ar fi fost luata doar daca distributia datelor ar fi permis acest lucru, deoarece aceste metode nu sunt potrivite in toate situatiile.

```
...  
Verificarea valorilor lipsă:  
school      0  
sex         0  
age         0  
address     0  
famsize     0  
Pstatus     0  
Medu        0  
Fedu        0  
Mjob        0  
Fjob        0  
reason      0  
guardian    0  
traveltime  0  
studytime   0
```

Setul contine coloane cu valori text, cum ar fi “school”, “address” sau raspunsurile “yes” si “no”. Pentru a le folosi in analiza, le-am transformat in valori numerice folosind **LabelEncoder**, astfel incat fiecare categorie sa aiba un cod propriu.

```

28 # in acest set avem variabile de tip text ("school", "address", "yes"/"no"), trebuie
29 # aplicam LabelEncoder pe toate coloanele de tip "obiect"
30 label_encoder = LabelEncoder()
31 cat_cols = df.select_dtypes(include="object").columns.tolist()
32
33 for col in cat_cols:
34     df[col] = label_encoder.fit_transform(df[col])
35
36 print("După codare: ")
37 print(df[cat_cols + ['age', 'G1', 'G2', 'G3']].head(), "\n")
38

```

dtype: int64

După codare:

	school	sex	address	famsize	Pstatus	Mjob	...	internet	romantic	age	G1	G2	G3
0	0	0	1	0	0	0	...	0	0	18	5	6	0
1	0	0	1	0	1	0	...	1	0	17	5	5	6
2	0	0	1	1	1	0	...	1	0	15	7	8	10
3	0	0	1	0	1	1	...	1	1	15	15	14	15
4	0	0	1	0	1	2	...	0	0	16	6	10	10

[5 rows x 21 columns]

Pentru coloanele text cu mai mult de doua valori (de exemplu Mjob, reason, guardian), am folosit **One-Hot Encoding**, pentru a evita introducerea unei ordini false intre valori.

Apoi am aplicat scalarea datelor cu metoda **Min-Max**, pentru a aduce toate valorile numerice pe acelasi interval, intre 0 si 1. Am aplicat transformarea doar pe variabilele de intrare, fara a modifica notele G1, G2 si G3.

```

39 # scalare Min-Max (NUMAI pe features, NU pe G1,G2,G3)
40 target_cols = ['G1', 'G2', 'G3']
41 feat_cols = [c for c in df.columns if c not in target_cols]
42
43 scaler = MinMaxScaler()
44 df_scaled = df.copy()
45 df_scaled[feat_cols] = scaler.fit_transform(df_scaled[feat_cols])
46 df_scaled[feat_cols] = df_scaled[feat_cols].round(3) # lizibil in Excel
47
48 print("După scalare: ")
49 print(df_scaled.head(), "\n")
50

```

PROBLEMS 84 OUTPUT DEBUG CONSOLE TERMINAL PORTS SPELL CHECKER 84

(.venv) PS C:\Users\mihae\Desktop\Master anul 2\MADDM\Project_Student_Performance> python

...

[5 rows x 21 columns]

După scalare:


	school	sex	age	address	famsize	Pstatus	...	Walc	health	absences	G1	G2	G3
0	0.0	0.0	0.429	1.0	0.0	0.0	...	0.00	0.5	0.080	5	6	6
1	0.0	0.0	0.286	1.0	0.0	1.0	...	0.00	0.5	0.053	5	5	6
2	0.0	0.0	0.000	1.0	1.0	1.0	...	0.50	0.5	0.133	7	8	10
3	0.0	0.0	0.000	1.0	0.0	1.0	...	0.00	1.0	0.027	15	14	15
4	0.0	0.0	0.143	1.0	0.0	1.0	...	0.25	1.0	0.053	6	10	10

[5 rows x 33 columns]

Salvat: student-mat-preprocessed.csv

Pentru comparatie, am aplicat si scalarea **Z-score**, care aduce datele la media 0 si deviatia standard 1.

Pentru o vizualizare rapida, am realizat o histograma a coloanei G3, care arata ca majoritatea elevilor au note intre 8 si 15.



In final, am salvat datele preprocesate in fisierul student-mat-preprocessed-minmax.csv si student-mat-preprocessed-zscore.csv.

In urma aplicarii celor doua metode de scalare, se observa ca Min-Max pastreaza valorile intr-un interval restrans intre 0 si 1, fiind usor de interpretat vizual, in timp ce Z-score produce valori pozitive si negative, centrate in jurul mediei 0.

Z-score poate fi mai potrivit pentru algoritmi sensibili la distributia datelor, in timp ce Min-Max este mai usor de interpretat vizual.

2. Clasificarea

Pentru aceasta parte am continuat sa lucrez pe setul de date preprocesat mai sus, Student_Performance, bazat pe performanta elevilor, asupra caruia am aplicat un algoritm de clasificare.

Am ales algoritmul **Random Forest Classifier**, deoarece ofera o precizie buna si permite observarea influentei parametrilor diferiti asupra predictiei.

Am creat o noua coloana numita target, care indica daca un elev este promovat (1 = nota finala (G3) \geq 10) sau nepromovat (0 = G3 < 10).

```
# ...  
cv  # rulam 10-fold cross-validation pentru fiecare configuratie  
me:  
    for params in configs:  
        model = RandomForestClassifier(random_state=42, **params)  
        print(f"\nConfiguratie: {params}")  
        res = {}  
        for m in metrics:  
            scores = cross_val_score(model, X, y, cv=cv, scoring=m)  
            mean_score = scores.mean()  
            print(f"{m:>9}: {mean_score:.3f}")  
            res[m] = mean_score  
        results.append({'config': params, **res})
```

Pentru evaluare am folosit metoda **10-fold cross-validation**, prin care setul de date este impartit in zece parti pentru antrenare si testare succesiva. Am analizat performanta modelului folosind mai multe metriki: **accuracy**, **precision**, **recall** si **F1-score**.

Am modificat parametrii n_estimators (numărul de arbori) și max_depth (adâncimea maximă a arborilor) pentru a observa efectul asupra performanței modelului. În general, creșterea numărului de arbori a dus la rezultate mai stabile, însă după un anumit prag îmbunătățirile au fost minore.

Pentru datele scalate cu **Min-Max**, cea mai bună configurație a fost n_estimators = 100 și max_depth = 10, cu un scor **F1** mediu de aproximativ **0.82**.

Pentru datele scalate cu **Z-score**, performanțele au fost ușor mai scăzute, scorul **F1** maxim fiind de aproximativ **0.81**.

```
PS C:\Users\mihae\Desktop\master_an2\ADDI\Project_Student_Performance> .venv\Scripts\activate  
● (.venv) PS C:\Users\mihae\Desktop\master_an2\ADDI\Project_Student_Performance> python clasificare.py  
Evaluare RandomForest pentru fisierul: student-mat-preprocessed-minmax.csv  
  
Configuratie: {'n_estimators': 50, 'max_depth': 5}  
accuracy: 0.694  
precision: 0.796  
recall: 0.932  
f1: 0.803  
  
Configuratie: {'n_estimators': 100, 'max_depth': 10}  
accuracy: 0.724  
precision: 0.736  
recall: 0.921  
f1: 0.817  
  
Configuratie: {'n_estimators': 200, 'max_depth': None}  
accuracy: 0.717  
precision: 0.733  
recall: 0.910  
f1: 0.811  
  
Rezumat configuratiilor pentru: student-mat-preprocessed-minmax.csv  
{'config': {'n_estimators': 50, 'max_depth': 5}, 'accuracy': np.float64(0.6935256410256411), 'precision': np.float64(0.7063813416116049), 'recall': np.float64(0.9319088319088319), 'f1': np.float64(0.8030195395041811)}  
{'config': {'n_estimators': 100, 'max_depth': 10}, 'accuracy': np.float64(0.7241666666666667), 'precision': np.float64(0.7362551190876809), 'recall': np.float64(0.9207977267977208), 'f1': np.float64(0.817426814407975)}  
{'config': {'n_estimators': 200, 'max_depth': None}, 'accuracy': np.float64(0.7166666666666666), 'precision': np.float64(0.7334388202984028), 'recall': np.float64(0.9095441595441596), 'f1': np.float64(0.8114620648553617)}  
[OK] Rezultate salvate in 'rezultate_clasificare_rf_cv10_student-mat-preprocessed-minmax.csv.csv'
```

```
Evaluare RandomForest pentru fisierul: student-mat-preprocessed-zscore.csv
Configuratie: {'n_estimators': 50, 'max_depth': 5}
    f1: 0.818

Configuratie: {'n_estimators': 100, 'max_depth': 10}
    accuracy: 0.706
    precision: 0.723
    recall: 0.913
    f1: 0.807

Configuratie: {'n_estimators': 200, 'max_depth': None}
    accuracy: 0.699
    precision: 0.715
    recall: 0.917
    f1: 0.803

Rezumat configuratii pentru: student-mat-preprocessed-zscore.csv
{'config': {'n_estimators': 50, 'max_depth': 5}, 'accuracy': np.float64(0.7061538461538461), 'precision': np.float64(0.7149027312011858), 'recall': np.float64(0.9354700854700855), 'f1': np.float64(0.8180239378128171)}
{'config': {'n_estimators': 100, 'max_depth': 10}, 'accuracy': np.float64(0.7062820512820512), 'precision': np.float64(0.7232473830196791), 'recall': np.float64(0.9131054131054132), 'f1': np.float64(0.806843498658853)}
{'config': {'n_estimators': 200, 'max_depth': None}, 'accuracy': np.float64(0.6987820512820513), 'precision': np.float64(0.7151239283592224), 'recall': np.float64(0.917894017054017), 'f1': np.float64(0.8033247206488662)}

[OK] Rezultate salvate in 'rezultate_clasificare_rf_cv10_student-mat-preprocessed-zscore.csv.csv'
(.venv) PS C:\Users\mihae\Desktop\master_an2\Hadoop\Project_Student_Performance>
```

În concluzie, algoritmul Random Forest Classifier s-a dovedit potrivit pentru problema de clasificare a promovării elevilor, oferind rezultate stabile în cadrul validării 10-fold.

Compararea celor două metode de scalare a arătat că Min-Max a oferit rezultate ușor mai bune decât Z-score în acest caz, însă diferențele nu sunt foarte mari (0.01).

Eliminarea notelor G1 și G2 a permis o evaluare corectă a modelului, fără informații care influențează direct nota finală.

3. Clustering

3.1 Rezumat Articol „K-means clustering algorithm and Python implementation”

Articolul "K-means clustering algorithm and Python implementation" prezinta algoritmul K-means, un algoritm clasic de invatare nesupravegheata folosit pentru gruparea automata a datelor in clustere. Principiul de baza este ca elementele din acelasi cluster trebuie sa fie similare, iar distanta, de obicei cea Euclidiana, este utilizata pentru a masura aceasta apropiere.

Autorul descrie propria implementarea a algoritmului, realizata printr-un API si cod in Python, folosind Java pentru generarea datelor experimentale. Procedura urmeaza pasii standard: alegerea aleatorie a K centroizi, atribuirea fiecarui obiect la cel mai apropiat centru si recalcularea centroizilor pe baza mediei, repetand procesul pana la convergenta.

Experimentele au fost efectuate pe un set de date cu un milion de inregistrari, iar rezultatele obtinute au fost similare cu cele generate de implementarea K-means din Apache Spark. Articolul subliniaza si limitarile algoritmului, precum necesitatea stabilirii valorii K si sensibilitatea la valori anormale.

3.2 Aplicarea algoritmului K-means pe setul Student Performance (Python, sklearn)

Am aplicat algoritmul **K-means** pe setul Student Performance preprocesat la inceput, folosind variantele scalate cu **Min-Max** si **Z-score**.

Datele au fost incarcate din fisiere CSV, iar coloanele G1, G2 si G3 au fost eliminate, deoarece K-means este un algoritm nesupravegheat.

Modelul a fost antrenat cu $K = 2, 3$ si 4 , folosind implementarea KMeans din scikit-learn, cu initializare aleatorie a centroizilor. Pentru fiecare valoare K au fost calculate metricele **WCSS** si **Silhouette Score**.

Cele mai bune rezultate au fost obtinute pentru datele scalate cu **Min-Max**, in cazul $K = 4$, unde **Silhouette Score** a fost aproximativ **0.30**, ceea ce arata ca studentii pot fi impartiti mai clar in patru grupuri.

Pentru varianta scalata cu **Z-score**, cea mai buna configuratie a fost $K = 2$, dar cu o separare mai slaba intre grupuri, unde **Silhouette Score** a fost aproximativ **0.15**.

Pentru evaluarea modelului am ales **WCSS** deoarece este metrica folosita direct de algoritmul K-means pentru a forma grupuri cat mai compacte.

Am utilizat si **Silhouette Score** pentru a verifica cat de bine sunt separate grupurile intre ele.

Rezultatele arata ca studentii pot fi impartiti in mai multe categorii, in functie de nivel de implicare scolara, cum ar fi prezenta la cursuri, timpul de studiu si suportul familial. Chiar daca diferențele nu sunt foarte mari, modelul ajuta la intelegerea modului in care studentii se grupeaza in functie de comportamentul lor scolar.

```
PS C:\Users\mihae\Desktop\master_an2\MADDM\Project_Student_Performance> .\venv\Scripts\activate
● (.\venv) PS C:\Users\mihae\Desktop\master_an2\MADDM\Project_Student_Performance> python kmeans_clustering.py

Clustering K-means pentru fisierul: student-mat-preprocessed-minmax.csv
Dimensiune set de date: (395, 39)

Rulare K-means cu K = 2
Silhouette score: 0.2610633291079305
WCSS: 49486287.903445095

Rulare K-means cu K = 3
Silhouette score: 0.26005901931818287
WCSS: 40159874.09994477

Rulare K-means cu K = 4
Silhouette score: 0.29596813929123594
WCSS: 33104090.517095327
Rezultate metrice salvate in: rezultate_clustering_kmeans_student-mat-preprocessed-minmax.csv.csv
Clustere finale salvate in: clustere_kmeans_K4_student-mat-preprocessed-minmax.csv

Clustering K-means pentru fisierul: student-mat-preprocessed-zscore.csv
Dimensiune set de date: (395, 39)

Rulare K-means cu K = 2
Silhouette score: 0.15302502011299593
WCSS: 4510302412718668.0


Rulare K-means cu K = 3
Silhouette score: 0.1045560419200294
WCSS: 4126518451452694.0

Rulare K-means cu K = 4
Silhouette score: 0.09622254738234111
WCSS: 3885829183780169.0
Rezultate metrice salvate in: rezultate_clustering_kmeans_student-mat-preprocessed-zscore.csv.csv
Clustere finale salvate in: clustere_kmeans_K2_student-mat-preprocessed-zscore.csv
```


4. Vizualizarea Datelor

Setul de date Student Performance contine informatii despre elevi si nota finala G3.


In primul grafic, histograma notei G3 arata o distributie concentrata in zona valorilor medii, cu cei mai multi elevi avand note intre aproximativ 8 si 14. Se observa si un numar vizibil de elevi cu nota finala G3 egala cu 0, care corespund cazurilor de nepromovare sau neprezentare la evaluare si nu reprezinta erori in setul de date.



Al doilea grafic, prezinta media notei G3 pe fiecare nivel de studytime, evidențiază o creștere a mediei notei finale pe măsură ce crește timpul de studiu. Elevii din grupele cu studytime 3 și 4 obțin, în medie, rezultate mai bune decât cei din grupele 1 și 2, ceea ce sugerează că timpul de studiu are un impact pozitiv asupra performanței scolare.



Al treilea grafic surprinde relatia dintre numarul de absente si nota finala G3, impreuna cu o curba de trend. Curba indica o relatie slabă și neliniară între absente și performanță, fără a sugera o legătură cauzală directă. În ansamblu, graficele arată că timpul de studiu influențează mai clar rezultatele finale decât numarul de absente.



5. Concluzii

In concluzie, analiza setului de date Student Performance a aratat ca timpul de studiu este un factor mai relevant pentru performanta scolară decat absentele.

Algoritmul Random Forest a oferit rezultate stabile pentru clasificarea promovarii elevilor, iar clustering-ul K-means a permis identificarea unor grupuri de elevi cu comportamente similare.

Vizualizarea datelor a completat analiza, oferind o interpretare clara si intuitiva a rezultatelor obtinute.